Prueba Técnica Departamento de Datos no Estructurados

<p style=»text-align: justify;»> El Departamento de Analítica No estructurada busca profesionales con fuertes capacidades técnicas y sobretodo una fuerte capacidad analítica. Por consiguiente esta prueba intenta poner a prueba la forma en la que plantea y soluciona problmeas. Es importante que presente el código que usa para resolver el problema con el único motivo de medir sus capacidades.

Se recomienda que sea ordenado en su código y siga los lineamientos establecidos, aún así la prueba tiene un grado de flexibilidad. Se evaluará el orden y la creatividad a la hora de presentar la información. </p>

Nota
Tenga en cuenta que éste ejercicio es hipotético y el banco no usará su trabajo más que para evaluar sus habiliadades para el cargo

Objetivo

El objetivo de esta prueba es lograr un filtro que discrimine automáticamente un tipo de documento sin información relevante: páginas en blanco. Se busca que este filtro reciba como entrada una carpeta con imágenes de documentos diversos y produzca como salida dos carpetas, una con imágenes de páginas en blanco y otra con imágenes de páginas con contenido.

Páginas con solo el membrete del documento se consideran páginas en blanco, así como las que, al momento de ser escaneadas, alcanzan a reflejar contenido ininteligible del reverso de la página.

Clasificación de Imágenes

0.Librerías

In [37]:
```
!pip install -r requirements.txt
```

In [10]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import os

from numpy import mean
from numpy import std
from scipy.stats import truncnorm

from PIL import Image
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Conv2D, MaxPooling2D, Flatten, Dense
from tensorflow.keras.preprocessing.image import ImageDataGenerator
from sklearn.model_selection import train_test_split

import glob

import matplotlib.image as mpimg
```

1.Importe las imágenes

En la carpeta adjunta se encontrará con documentos tanto en blanco como con contenido. Su objetivo es generar un modelo que clasifique los elementos en "Con Contenido" y "Sin Contenido". Para eso puede utilizar reglas o modelos especificos.

In [12]:
```
def mostrar_imagenes(carpeta, num_imagenes=2):
    imagenes = [f for f in os.listdir(carpeta) if f.endswith(('.png'))]
    imagenes = imagenes[:num_imagenes]

    fig, axes = plt.subplots(1, num_imagenes, figsize=(10, 10))
    for ax, img in zip(axes, imagenes):
        img_path = os.path.join(carpeta, img)
        img_data = mpimg.imread(img_path)
        ax.imshow(img_data, cmap='gray')
        ax.axis('off')
        ax.set_title(img)
    plt.show()

# Mostrar imágenes de la carpeta Blanco
mostrar_imagenes('Imagenes/Blanco')

# Mostrar imágenes de la carpeta Documentos
mostrar_imagenes('Imagenes/Documentos')
```

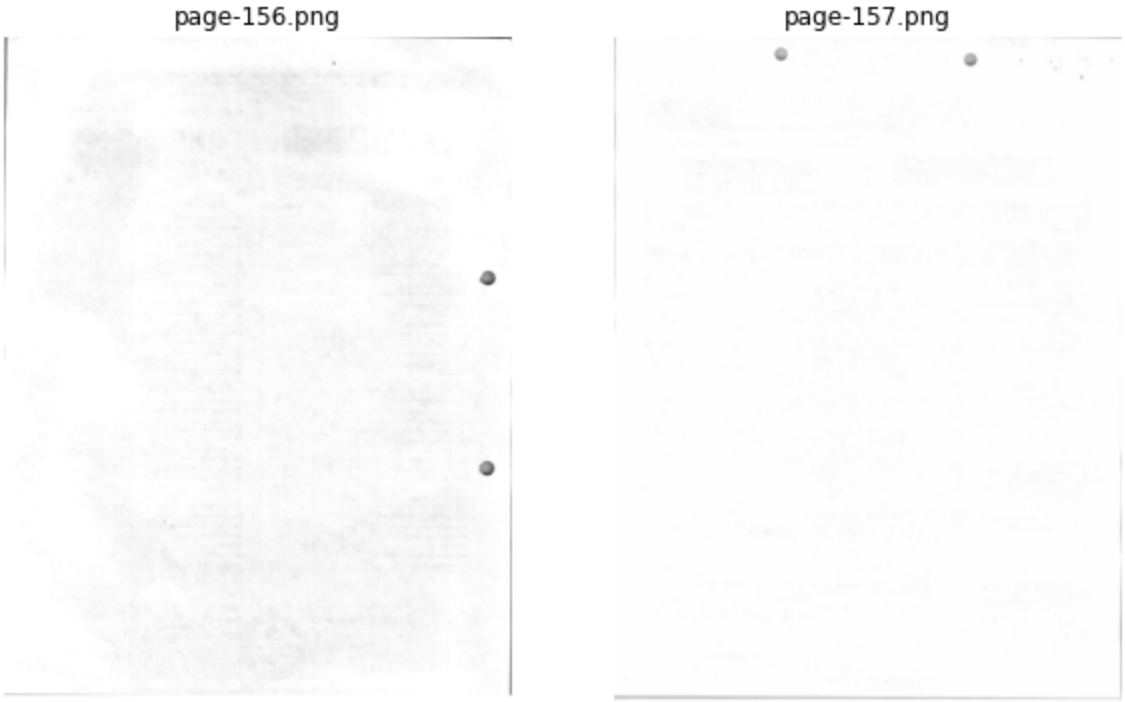

page-10.png

page-107.png

In [13]:

```
# Definir la lista de rutas de imágenes
imgList = [
    'Imagenes/Documentos/page-2.png'
]

# Función para redimensionar la imagen manteniendo la relación de aspecto
def resizeAspect(im, size):
    w, h = im.size
    aspect = max(size[0] / float(w), size[1] / float(h))
    return im.resize((int(w * aspect), int(h * aspect)), Image.LANCZOS)

# Función para centrar la imagen en un lienzo de tamaño fijo
def centerImage(im, size):
    w, h = im.size
    new_im = Image.new("RGB", size, (255, 255, 255))  # Crear un lienzo blanco
    new_im.paste(im, ((size[0] - w) // 2, (size[1] - h) // 2))
    return new_im

# Procesar solo una imagen de ejemplo
img_path = imgList[0]
img = Image.open(img_path)

# Imprimir las dimensiones de la imagen antes de preprocesar
print(f"Dimensiones de la imagen antes de preprocesar: {img.size}")

# Mostrar la imagen antes del preprocesamiento
plt.figure(figsize=(10, 10))
plt.imshow(img, cmap='gray')
plt.title('Antes del preprocesamiento')
plt.axis('off')
plt.show()

# Preprocesar la imagen
w, h = img.size
if min(w, h) < 1500:
    img = resizeAspect(img, (448, 448))
    w, h = img.size
center = [int(w / 2), int(h / 2)]
box = (center[0] - 224, center[1] - 224, center[0] + 224, center[1] + 224)
cropped_img = img.crop(box)
```

```python
# Imprimir las dimensiones de la imagen después de preprocesar
print(f"Dimensiones de la imagen después de preprocesar: {cropped_img.size}")

# Mostrar la imagen después del preprocesamiento
plt.figure(figsize=(10, 10))
plt.imshow(cropped_img, cmap='gray')
plt.title('Después del preprocesamiento')
plt.axis('off')
plt.show()

# Convertir la imagen a un array y aplanarla
img_array = np.array(cropped_img).flatten()

# Determinar la etiqueta basada en el nombre del archivo
etiqueta = 0 if 'Blanco' in img_path else 1

# Imprimir la etiqueta de la imagen
print(f"Etiqueta de la imagen: {etiqueta}")
```

```
Dimensiones de la imagen antes de preprocesar: (1224, 1584)
```

Our study is novel in that it looks at student mistakes from a much larger number of students (over 250,000) from a large number of institutions[1], thus providing more robust data about error frequencies, and error commonality. The Blackbox work was originally presented with a brief list of the most frequent compiler error messages [3], but in this study we do not simply use compiler error messages to classify errors. Instead, we borrow error classifications from Hristova et al. [6], which are based on surveying educators to ask for the most common Java mistakes they saw among their students.

3. METHOD

3.1 Student Mistakes

We use the 18 mistakes from our previous study [2] as a basis for our analysis, which in turn were derived from Hristova et al's [6] twenty student mistakes (derived from interviewing educators). The eighteen mistakes, labeled A through R, are informally categorized as follows:

Misunderstanding (or forgetting) syntax:

- **A**: Confusing the assignment operator (=) with the comparison operator (==).
  For example: `if (a = b) ...`
- **C**: Unbalanced parentheses, curly or square brackets and quotation marks, or using these different symbols interchangeably.
  For example: `while (a == 0]`
- **D**: Confusing "short-circuit" evaluators (`&&` and `||`) with conventional logical operators (`&` and `|`).
  For example: `if ((a == 0) & (b == 0)) ...`
- **E**: Incorrect semi-colon after an if selection structure before the if statement or after the for or while repetition structure before the respective for or while loop.
  For example:
  ```
  if (a == b);
      return 6;
  ```
- **F**: Wrong separators in for loops (using commas instead of semi-colons)
  For example: `for (int i = 0, i < 6, i++) ...`
- **G**: Inserting the condition of an if statement within curly brackets instead of parentheses.
  For example: `if {a == b} ...`
- **H**: Using keywords as method or variable names.
  For example: `int new;`
- **J**: Forgetting parentheses after a method call.
  For example: `myObject.toString;`
- **K**: Incorrect semicolon at the end of a method header.
  For example:
  ```
  public void foo();
  {
      ...
  }
  ```

[1]We have no way of measuring the number of institutions in the Blackbox data, but simply: the 250,000 students must be split over at least several hundred institutions.

- **L**: Getting greater than or equal/less than or equal wrong, i.e. using => or =< instead of >= and <=.
  For example: `if (a =< b) ...`
- **P**: Including the types of parameters when invoking a method.
  For example: `myObject.foo(int x, String s);`

Type errors:

- **I**: Invoking methods with wrong arguments (e.g. wrong types).
  For example: `list.get("abc")`
- **Q**: Incompatible types between method return and type of variable that the value is assigned to.
  For example: `int x = myObject.toString();`

Other semantic errors:

- **B**: Use of `==` instead of `.equals` to compare strings.
  For example: `if (a == "start") ...`
- **M**: Trying to invoke a non-static method as if it was static.
  For example: `MyClass.toString();`
- **N**: A method that has a non-void return type is called and its return value ignored/discarded.
  For example: `myObject.toString();`
- **O**: Control flow can reach end of non-void method without returning.
  For example:
  ```
  public int foo(int x)
  {
      if (x < 0)
          return 0;
      x += 1;
  }
  ```
- **R**: Class claims to implement an interface, but does not implement all the required methods.
  For example: `class Y implements ActionListener { }`

Note that mistake *N* (ignoring the non-void result of a method) is not always an error (e.g. when you call a remove method that returns the item removed, you may not need to do anything with the return value).

3.2 Student data

Data about student mistakes was taken from the Blackbox data set [3], which collects Java code written by users of BlueJ, the Java beginners' IDE. We used data from the period 1st Sep. 2013 to 31st Aug. 2014 (inclusive), as representing a full year.

We had two methods of detecting mistakes. For four of the student mistakes, *I*, *M*, *O*, *R*, we were able to use the compiler error message directly from Blackbox's compilations to detect the mistake. However, this was not possible for the other errors, as some of them are logical errors that do not cause a compiler error or warning, while in other cases the error messages do not have a one-to-one mapping to our mistakes of interest. Thus for one of the other mistakes (*C*) we performed a post-lexing analysis (matching brackets) and for the final thirteen we used a customized permissive parser

```
Dimensiones de la imagen después de preprocesar: (448, 448)
```

Después del preprocesamiento

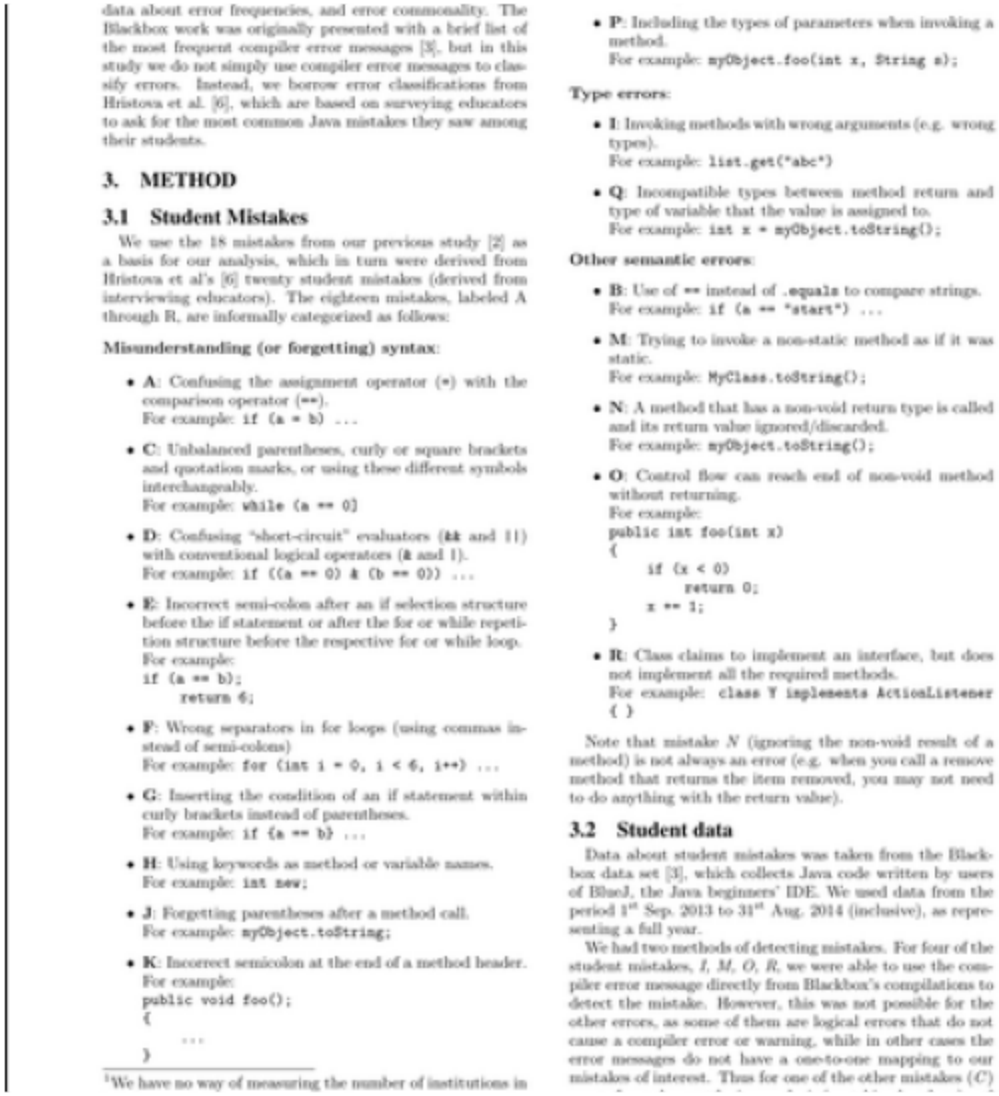

data about error frequencies, and error commonality. The Blackbox work was originally presented with a brief list of the most frequent compiler error messages [3], but in this study we do not simply use compiler error messages to classify errors. Instead, we borrow error classifications from Hristova et al. [6], which are based on surveying educators to ask for the most common Java mistakes they saw among their students.

3. METHOD

3.1 Student Mistakes

We use the 18 mistakes from our previous study [2] as a basis for our analysis, which in turn were derived from Hristova et al's [6] twenty student mistakes (derived from interviewing educators). The eighteen mistakes, labeled A through R, are informally categorized as follows:

Misunderstanding (or forgetting) syntax:

- **A**: Confusing the assignment operator (=) with the comparison operator (==).
  For example: `if (a = b) ...`
- **C**: Unbalanced parentheses, curly or square brackets and quotation marks, or using these different symbols interchangeably.
  For example: `while (a == 0]`
- **D**: Confusing "short-circuit" evaluators (`&&` and `||`) with conventional logical operators (`&` and `|`).
  For example: `if ((a == 0) & (b == 0)) ...`
- **E**: Incorrect semi-colon after an if selection structure before the if statement or after the for or while repetition structure before the respective for or while loop.
  For example:
  ```
  if (a == b);
      return 6;
  ```
- **F**: Wrong separators in for loops (using commas instead of semi-colons)
  For example: `for (int i = 0, i < 6, i++) ...`
- **G**: Inserting the condition of an if statement within curly brackets instead of parentheses.
  For example: `if {a == b} ...`
- **H**: Using keywords as method or variable names.
  For example: `int new;`
- **J**: Forgetting parentheses after a method call.
  For example: `myObject.toString;`
- **K**: Incorrect semicolon at the end of a method header.
  For example:
  ```
  public void foo();
  {
      ...
  }
  ```

[1]We have no way of measuring the number of institutions in

- **P**: Including the types of parameters when invoking a method.
  For example: `myObject.foo(int x, String s);`

Type errors:

- **I**: Invoking methods with wrong arguments (e.g. wrong types).
  For example: `list.get("abc")`
- **Q**: Incompatible types between method return and type of variable that the value is assigned to.
  For example: `int x = myObject.toString();`

Other semantic errors:

- **B**: Use of `==` instead of `.equals` to compare strings.
  For example: `if (a == "start") ...`
- **M**: Trying to invoke a non-static method as if it was static.
  For example: `MyClass.toString();`
- **N**: A method that has a non-void return type is called and its return value ignored/discarded.
  For example: `myObject.toString();`
- **O**: Control flow can reach end of non-void method without returning.
  For example:
  ```
  public int foo(int x)
  {
      if (x < 0)
          return 0;
      x += 1;
  }
  ```
- **R**: Class claims to implement an interface, but does not implement all the required methods.
  For example: `class Y implements ActionListener { }`

Note that mistake *N* (ignoring the non-void result of a method) is not always an error (e.g. when you call a remove method that returns the item removed, you may not need to do anything with the return value).

3.2 Student data

Data about student mistakes was taken from the Blackbox data set [3], which collects Java code written by users of BlueJ, the Java beginners' IDE. We used data from the period 1st Sep. 2013 to 31st Aug. 2014 (inclusive), as representing a full year.

We had two methods of detecting mistakes. For four of the student mistakes, *I*, *M*, *O*, *R*, we were able to use the compiler error message directly from Blackbox's compilations to detect the mistake. However, this was not possible for the other errors, as some of them are logical errors that do not cause a compiler error or warning, while in other cases the error messages do not have a one-to-one mapping to our mistakes of interest. Thus for one of the other mistakes (*C*)

```
Etiqueta de la imagen: 1
```

Como en este ejercicio no nos interesa analizar el contenido de los documentos, realizamos un proceso de re escalamiento de las imagenes para que sean más ligeras y fáciles de interpretar para el modelo.

2. Estructure la información

Debido a que las imagenes son archivos separados lo primero que debe hacer es importarlas (recuerde que una imagen es esencialmente un arreglo de vectores), puede esturcturarlas a su gusto y marcar de ser necesario aquellas que va usar como test de pruebas.

In [38]:
```python
import os
import random
from PIL import Image
import numpy as np

# Función para redimensionar la imagen manteniendo la relación de aspecto
def resizeAspect(im, size):
    w, h = im.size
    aspect = max(size[0] / float(w), size[1] / float(h))
    return im.resize((int(w * aspect), int(h * aspect)), Image.LANCZOS)

# Función para centrar la imagen en un lienzo de tamaño fijo
def centerImage(im, size):
    w, h = im.size
    new_im = Image.new("RGB", size, (255, 255, 255))  # Crear un lienzo blanco
```

```
    new_im.paste(im, ((size[0] - w) // 2, (size[1] - h) // 2))
    return new_im

run_preprocess = False

if run_preprocess == False:

    # Definir las carpetas de origen
    carpetas_origen = ['Imagenes/cropped/Blanco', 'Imagenes/cropped/Documentos']
    carpeta_destino = 'Imagenes/validar_final'

    # Crear las carpetas de destino si no existen
    os.makedirs(os.path.join(carpeta_destino, 'Blanco'), exist_ok=True)
    os.makedirs(os.path.join(carpeta_destino, 'Documentos'), exist_ok=True)

    # Seleccionar 10 imágenes al azar de cada carpeta para la validación final
    for carpeta in carpetas_origen:
        imagenes = [img for img in os.listdir(carpeta) if img.endswith('.png')]
        imagenes_validar = random.sample(imagenes, 10)

        for img_name in imagenes_validar:
            img_path = os.path.join(carpeta, img_name)
            if 'Blanco' in carpeta:
                destino_path = os.path.join(carpeta_destino, 'Blanco', img_name)
            elif 'Documentos' in carpeta:
                destino_path = os.path.join(carpeta_destino, 'Documentos', img_name)
            shutil.copy(img_path, destino_path)
#             print(f"Copiada: {img_path} a {destino_path}")


if run_preprocess:

    # Definir las carpetas de origen
    carpetas_origen = [
        'Imagenes/Documentos',
        'Imagenes/Blanco'
    ]
    carpeta_destino = 'Imagenes/cropped'
    carpeta_validar_final = 'Imagenes/validar_final'

    # Crear las subcarpetas de destino si no existen
    os.makedirs(os.path.join(carpeta_destino, 'Blanco'), exist_ok=True)
    os.makedirs(os.path.join(carpeta_destino, 'Documentos'), exist_ok=True)
    os.makedirs(os.path.join(carpeta_validar_final, 'Blanco'), exist_ok=True)
    os.makedirs(os.path.join(carpeta_validar_final, 'Documentos'), exist_ok=True)

    contador_blanco = 0
    contador_documentos = 0

    # Seleccionar 10 imágenes al azar de cada carpeta para la validación final
    imagenes_validar = {}
    for carpeta in carpetas_origen:
        imagenes = [img for img in os.listdir(carpeta) if img.endswith('.png')]
        imagenes_validar[carpeta] = random.sample(imagenes, 10)

    # Procesar todas las imágenes en las carpetas de origen
    for carpeta in carpetas_origen:
        for img_name in os.listdir(carpeta):
            if img_name.endswith('.png'):
                img_path = os.path.join(carpeta, img_name)
                img = Image.open(img_path)

                # Determinar la etiqueta basada en el nombre del archivo
                etiqueta = 'Blanco' if 'Blanco' in carpeta else 'Documentos'

                # Si la imagen está en la lista de validación, moverla a la carpeta de v
```

```
                if img_name in imagenes_validar[carpeta]:
                    validar_img_path = os.path.join(carpeta_validar_final, etiqueta, img
                    img.save(validar_img_path, 'PNG')
                    print(f"Imagen {img_name} movida a la carpeta de validación final.")
                    continue

                print(f"Dimensiones de la imagen antes de preprocesar: {img.size}")
                img = resizeAspect(img, (448, 448))
                img = centerImage(img, (448, 448))
                print(f"Dimensiones de la imagen después de preprocesar: {img.size}")

                # Guardar la imagen procesada en la subcarpeta de destino correspondient
                cropped_img_name = f"{os.path.splitext(img_name)[0]}_{etiqueta}.png"
                cropped_img_path = os.path.join(carpeta_destino, etiqueta, cropped_img_n
                img.save(cropped_img_path, 'PNG')

                if etiqueta == 'Blanco':
                    contador_blanco += 1
                else:
                    contador_documentos += 1

                print(f"Etiqueta de la imagen: {etiqueta}")

    print(f"Cantidad de imágenes en la carpeta 'Blanco': {contador_blanco}")
    print(f"Cantidad de imágenes en la carpeta 'Documentos': {contador_documentos}")

else:
    print("Las imágenes ya se encuentran preprocesadas")
```

```
Las imágenes ya se encuentran preprocesadas
```

3. Describa su Estrategia de Análisis

Tiene libertad en la metodología para la clasificación. Aún así debe describir brevemente como realizará el análisis. Por ejemplo, si usará un modelo en donde requiera clasificar una cantidad pequeña de la data mencionelo o si planea condicionar la clasifiaciónes a reglas indique que reglas usará. Además si usa herramientas externas describalas y explique.

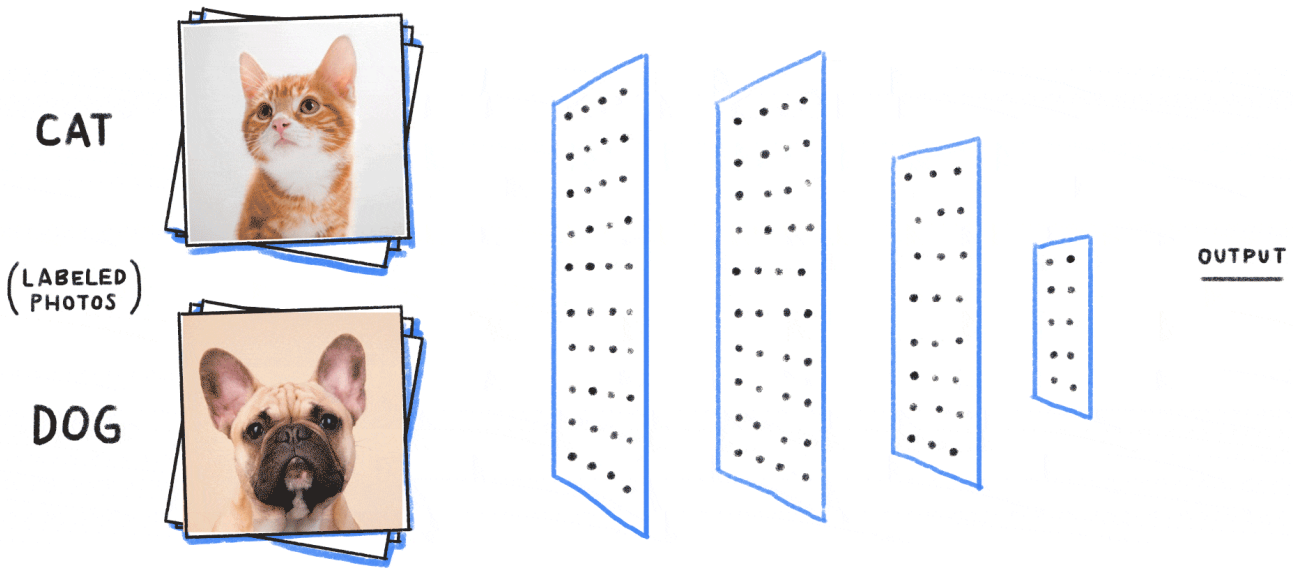

Se emplea un modelo convolucional que clasifica las imágenes basándose su contenido visual.

In [32]:
```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Conv2D, MaxPooling2D, Flatten, Dense, Dropout
from tensorflow.keras.optimizers import Adam
from tensorflow.keras.preprocessing.image import ImageDataGenerator
import os
import matplotlib.pyplot as plt

# Crear un generador de datos con aumento de datos
datagen = ImageDataGenerator(
    rescale=1.0/255.0,
    validation_split=0.2,
    rotation_range=20,
    width_shift_range=0.2,
    height_shift_range=0.2,
    shear_range=0.2,
    zoom_range=0.2,
    horizontal_flip=True,
    fill_mode='nearest'
)

# Cargar las imágenes de entrenamiento y validación
train_generator = datagen.flow_from_directory(
    'Imagenes/cropped',
    target_size=(224, 224),  # Reducir el tamaño de la imagen para acelerar el entrenami
    batch_size=32,
    class_mode='binary',
    subset='training'
)

validation_generator = datagen.flow_from_directory(
    'Imagenes/cropped',
    target_size=(224, 224),  # Reducir el tamaño de la imagen para acelerar el entrenami
    batch_size=32,
    class_mode='binary',
    subset='validation'
)

# Contar las imágenes de cada clase
blanco_count = sum(['Blanco' in f for f in train_generator.filenames])
documentos_count = sum(['Documentos' in f for f in train_generator.filenames])

print(f"Found {blanco_count} images belonging to 'Blanco' class.")
print(f"Found {documentos_count} images belonging to 'Documentos' class.")

# Definir el modelo con regularización y más capas de Dropout
model = Sequential([
    Conv2D(32, (3, 3), activation='relu', input_shape=(224, 224, 3)),
    MaxPooling2D((2, 2)),
    Conv2D(64, (3, 3), activation='relu'),
    MaxPooling2D((2, 2)),
    Conv2D(128, (3, 3), activation='relu'),
    MaxPooling2D((2, 2)),
    Flatten(),
    Dense(128, activation='relu'),
    Dropout(0.5),
    Dense(1, activation='sigmoid')
])

# Compilar el modelo
model.compile(optimizer=Adam(learning_rate=0.0001), loss='binary_crossentropy', metrics=

# Entrenar el modelo
history = model.fit(
```

```
    train_generator,
    epochs=25,  # Aumentar el número de épocas
    validation_data=validation_generator
)

# Guardar el modelo entrenado
model.save('modelo_clasificacion_paginas_mejorado.h5')
```

```
Found 182 images belonging to 2 classes.
Found 45 images belonging to 2 classes.
Found 110 images belonging to 'Blanco' class.
Found 72 images belonging to 'Documentos' class.
Epoch 1/25
6/6 ━━━━━━━━━━━━━━━━━━━━ 7s 973ms/step - accuracy: 0.5609 - loss: 0.7147 -
 val_accuracy: 0.4000 - val_loss: 0.6945
Epoch 2/25
6/6 ━━━━━━━━━━━━━━━━━━━━ 5s 796ms/step - accuracy: 0.5629 - loss: 0.7211 -
 val_accuracy: 0.6000 - val_loss: 0.6747
Epoch 3/25
6/6 ━━━━━━━━━━━━━━━━━━━━ 5s 782ms/step - accuracy: 0.6345 - loss: 0.6209 -
 val_accuracy: 1.0000 - val_loss: 0.5290
Epoch 4/25
6/6 ━━━━━━━━━━━━━━━━━━━━ 5s 771ms/step - accuracy: 0.8109 - loss: 0.4797 -
 val_accuracy: 0.7111 - val_loss: 0.4888
Epoch 5/25
6/6 ━━━━━━━━━━━━━━━━━━━━ 5s 769ms/step - accuracy: 0.8774 - loss: 0.3628 -
 val_accuracy: 0.9111 - val_loss: 0.3154
Epoch 6/25
6/6 ━━━━━━━━━━━━━━━━━━━━ 5s 778ms/step - accuracy: 0.9592 - loss: 0.2587 -
 val_accuracy: 0.9556 - val_loss: 0.2415
Epoch 7/25
6/6 ━━━━━━━━━━━━━━━━━━━━ 5s 776ms/step - accuracy: 0.9654 - loss: 0.1924 -
 val_accuracy: 0.8444 - val_loss: 0.2424
Epoch 8/25
6/6 ━━━━━━━━━━━━━━━━━━━━ 5s 831ms/step - accuracy: 0.9704 - loss: 0.1646 -
 val_accuracy: 0.9556 - val_loss: 0.1449
Epoch 9/25
6/6 ━━━━━━━━━━━━━━━━━━━━ 5s 767ms/step - accuracy: 0.9531 - loss: 0.1641 -
 val_accuracy: 0.9556 - val_loss: 0.1538
Epoch 10/25
6/6 ━━━━━━━━━━━━━━━━━━━━ 5s 791ms/step - accuracy: 0.9906 - loss: 0.0690 -
 val_accuracy: 0.9778 - val_loss: 0.0872
Epoch 11/25
6/6 ━━━━━━━━━━━━━━━━━━━━ 5s 861ms/step - accuracy: 0.9733 - loss: 0.0982 -
 val_accuracy: 0.9556 - val_loss: 0.1202
Epoch 12/25
6/6 ━━━━━━━━━━━━━━━━━━━━ 5s 875ms/step - accuracy: 0.9523 - loss: 0.1192 -
 val_accuracy: 1.0000 - val_loss: 0.0472
Epoch 13/25
6/6 ━━━━━━━━━━━━━━━━━━━━ 5s 850ms/step - accuracy: 0.9882 - loss: 0.0605 -
 val_accuracy: 0.9778 - val_loss: 0.0622
Epoch 14/25
6/6 ━━━━━━━━━━━━━━━━━━━━ 5s 875ms/step - accuracy: 0.9866 - loss: 0.0594 -
 val_accuracy: 0.9778 - val_loss: 0.0481
Epoch 15/25
6/6 ━━━━━━━━━━━━━━━━━━━━ 5s 831ms/step - accuracy: 0.9766 - loss: 0.0537 -
 val_accuracy: 1.0000 - val_loss: 0.0322
Epoch 16/25
6/6 ━━━━━━━━━━━━━━━━━━━━ 5s 806ms/step - accuracy: 0.9816 - loss: 0.0382 -
 val_accuracy: 0.9778 - val_loss: 0.0609
Epoch 17/25
6/6 ━━━━━━━━━━━━━━━━━━━━ 5s 846ms/step - accuracy: 0.9898 - loss: 0.0430 -
 val_accuracy: 0.9778 - val_loss: 0.0492
Epoch 18/25
6/6 ━━━━━━━━━━━━━━━━━━━━ 5s 869ms/step - accuracy: 0.9963 - loss: 0.0269 -
 val_accuracy: 0.9556 - val_loss: 0.0532
```

```
Epoch 19/25
6/6 ━━━━━━━━━━━━━━━━━━━━ 5s 822ms/step - accuracy: 0.9809 - loss: 0.0427 -
 val_accuracy: 0.9778 - val_loss: 0.0307
Epoch 20/25
6/6 ━━━━━━━━━━━━━━━━━━━━ 5s 795ms/step - accuracy: 0.9937 - loss: 0.0247 -
 val_accuracy: 0.9778 - val_loss: 0.0530
Epoch 21/25
6/6 ━━━━━━━━━━━━━━━━━━━━ 5s 832ms/step - accuracy: 0.9893 - loss: 0.0351 -
 val_accuracy: 0.9778 - val_loss: 0.0404
Epoch 22/25
6/6 ━━━━━━━━━━━━━━━━━━━━ 5s 834ms/step - accuracy: 0.9875 - loss: 0.0600 -
 val_accuracy: 0.9778 - val_loss: 0.0585
Epoch 23/25
6/6 ━━━━━━━━━━━━━━━━━━━━ 5s 826ms/step - accuracy: 0.9963 - loss: 0.0352 -
 val_accuracy: 1.0000 - val_loss: 0.0169
Epoch 24/25
6/6 ━━━━━━━━━━━━━━━━━━━━ 5s 789ms/step - accuracy: 0.9964 - loss: 0.0221 -
 val_accuracy: 0.9778 - val_loss: 0.0400
Epoch 25/25
6/6 ━━━━━━━━━━━━━━━━━━━━ 5s 874ms/step - accuracy: 0.9984 - loss: 0.0185 -
 val_accuracy: 0.9778 - val_loss: 0.0263
WARNING:absl:You are saving your model as an HDF5 file via `model.save()` or `keras.savi
ng.save_model(model)`. This file format is considered legacy. We recommend using instead
the native Keras format, e.g. `model.save('my_model.keras')` or `keras.saving.save_model
(model, 'my_model.keras')`.
```

4. Interpretación de Resultados

Al final tiene que presentar la información en una matriz que muestre la calidad de su clasificación y evaluarla con la medida que guste.

		Predicción	
		Positivos	**Negativos**
Observación	**Positivos**	Verdaderos Positivos (VP)	Falsos Negativos (FN)
	Negativos	Falsos Positivos (FP)	Verdaderos Negativos (VN)

Se estableció una muestra de 20 imanges para backtesting llamada `validar_final` con el fin de ver el desempeño del modelo.

In [36]:
```python
import os
import shutil
import numpy as np
import tensorflow as tf
from tensorflow.keras.models import load_model
from tensorflow.keras.preprocessing.image import load_img, img_to_array
from sklearn.metrics import confusion_matrix, ConfusionMatrixDisplay, classification_rep
import matplotlib.pyplot as plt

# Cargar el modelo entrenado
model = load_model('modelo_clasificacion_paginas_mejorado.h5')

# Crear carpetas de salida
output_dir_blanco = 'Imagenes/Blanco_evaluado'
output_dir_documentos = 'Imagenes/Documentos_evaluado'
os.makedirs(output_dir_blanco, exist_ok=True)
```

```
os.makedirs(output_dir_documentos, exist_ok=True)

def mover_imagenes(model, carpeta_entrada, umbral=0.5):
    y_true = []
    y_pred = []

    # Recorrer recursivamente las subcarpetas
    for root, dirs, files in os.walk(carpeta_entrada):
        for img_name in files:
            img_path = os.path.join(root, img_name)
            try:
                # Verificar que el archivo es una imagen
                if not img_name.lower().endswith(('.png', '.jpg', '.jpeg', '.bmp', '.gif
                    print(f"Archivo no soportado: {img_name}")
                    continue

                img = load_img(img_path, target_size=(224, 224))  # Asegurarse de que el
                img_array = img_to_array(img)
                img_array = np.expand_dims(img_array, axis=0) / 255.0

                prediccion = model.predict(img_array)
                prediccion_clase = 0 if prediccion < umbral else 1
                y_pred.append(prediccion_clase)

                # Etiqueta verdadera basada en la carpeta origen
                if 'Blanco' in root:
                    etiqueta_verdadera = 0
                elif 'Documentos' in root:
                    etiqueta_verdadera = 1
                else:
                    print(f"Carpeta desconocida: {root}")
                    continue
                y_true.append(etiqueta_verdadera)

                # Mover la imagen a la carpeta correspondiente
                if prediccion_clase == 0:
                    shutil.move(img_path, os.path.join(output_dir_blanco, img_name))
                else:
                    shutil.move(img_path, os.path.join(output_dir_documentos, img_name))

                # Imprimir información de depuración
                print(f"Imagen: {img_name}, Predicción: {prediccion[0][0]}, Clase Predic
            except PermissionError:
                print(f"Permiso denegado para el archivo: {img_path}")
            except Exception as e:
                print(f"Error procesando el archivo {img_path}: {e}")

    return y_true, y_pred

# Evaluar y mover las imágenes
y_true, y_pred = mover_imagenes(model, 'Imagenes/validar_final', umbral=0.5)

if y_true and y_pred:
    # Calcular la matriz de confusión
    cm = confusion_matrix(y_true, y_pred, labels=[0, 1])
    disp = ConfusionMatrixDisplay(confusion_matrix=cm, display_labels=['Blanco', 'Docume

    # Mostrar la matriz de confusión
    disp.plot(cmap=plt.cm.Blues)
    plt.show()

    # Calcular y mostrar las métricas de clasificación
    report = classification_report(y_true, y_pred, target_names=['Blanco', 'Documentos']
    print(report)
else:
    print("No se encontraron imágenes válidas para evaluar.")
```

```
WARNING:absl:Compiled the loaded model, but the compiled metrics have yet to be built. `model.compile_metrics` will be empty until you train or evaluate the model.
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 166ms/step
Imagen: page-158_Blanco.png, Predicción: 0.00839244481176138, Clase Predicha: 0, Clase Verdadera: 0
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 70ms/step
Imagen: page-181_Blanco.png, Predicción: 0.006868349388241768, Clase Predicha: 0, Clase Verdadera: 0
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 57ms/step
Imagen: page-197_Blanco.png, Predicción: 0.006807956378906965, Clase Predicha: 0, Clase Verdadera: 0
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 58ms/step
Imagen: page-220_Blanco.png, Predicción: 0.006538487039506435, Clase Predicha: 0, Clase Verdadera: 0
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 51ms/step
Imagen: page-223_Blanco.png, Predicción: 0.006981114856898785, Clase Predicha: 0, Clase Verdadera: 0
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 75ms/step
Imagen: page-238_Blanco.png, Predicción: 0.007121229078620672, Clase Predicha: 0, Clase Verdadera: 0
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 53ms/step
Imagen: page-252_Blanco.png, Predicción: 0.0069662523455917835, Clase Predicha: 0, Clase Verdadera: 0
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 67ms/step
Imagen: page-257_Blanco.png, Predicción: 0.00653996504843235, Clase Predicha: 0, Clase Verdadera: 0
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 60ms/step
Imagen: page-261_Blanco.png, Predicción: 0.010118985548615456, Clase Predicha: 0, Clase Verdadera: 0
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 64ms/step
Imagen: page-262_Blanco.png, Predicción: 0.01532309502363205, Clase Predicha: 0, Clase Verdadera: 0
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 75ms/step
Imagen: page-119_Documentos.png, Predicción: 1.0, Clase Predicha: 1, Clase Verdadera: 1
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 73ms/step
Imagen: page-34_Documentos.png, Predicción: 0.9999985694885254, Clase Predicha: 1, Clase Verdadera: 1
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 57ms/step
Imagen: page-36_Documentos.png, Predicción: 1.0, Clase Predicha: 1, Clase Verdadera: 1
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 52ms/step
Imagen: page-42_Documentos.png, Predicción: 1.0, Clase Predicha: 1, Clase Verdadera: 1
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 65ms/step
Imagen: page-4_Documentos.png, Predicción: 1.0, Clase Predicha: 1, Clase Verdadera: 1
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 69ms/step
Imagen: page-50_Documentos.png, Predicción: 1.0, Clase Predicha: 1, Clase Verdadera: 1
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 54ms/step
Imagen: page-77_Documentos.png, Predicción: 1.0, Clase Predicha: 1, Clase Verdadera: 1
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 67ms/step
Imagen: page-83_Documentos.png, Predicción: 1.0, Clase Predicha: 1, Clase Verdadera: 1
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 61ms/step
Imagen: page-8_Documentos.png, Predicción: 1.0, Clase Predicha: 1, Clase Verdadera: 1
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 56ms/step
Imagen: page-9_Documentos.png, Predicción: 1.0, Clase Predicha: 1, Clase Verdadera: 1
```

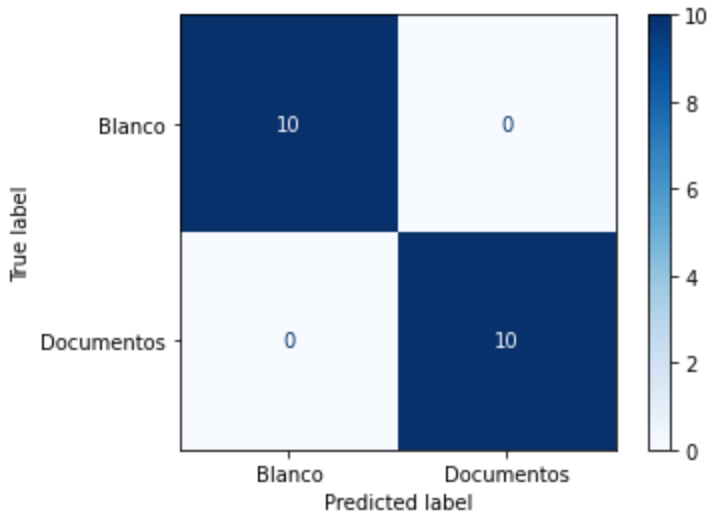

	precision	recall	f1-score	support
Blanco	1.00	1.00	1.00	10
Documentos	1.00	1.00	1.00	10
accuracy			1.00	20
macro avg	1.00	1.00	1.00	20
weighted avg	1.00	1.00	1.00	20

SE EVIDENCIA UN BUEN RENDIMIENTO DEL MODELO, PREDICIENDO CORRECTAMENTE TODAS LAS IMAGENES DEL BACK TESTING